

Análisis de ganadería de precisión aplicando compresión de imágenes.

Jose Muñoz
Universidad Eafit
Colombia
jmmunozr@eafit.edu.co

Mauricio Correa
Universidad Eafit
Colombia
mdcorreah@eafit.edu.co

Simón Marín
Universidad Eafit
Colombia
smaring1@eafit.edu.co

Mauricio Toro
Universidad Eafit
Colombia
mtorobe@eafit.edu.co

Para cada versión de este informe: 1. Elimine todo el texto en rojo. 2. Ajustar los espacios entre las palabras y los párrafos. 3. Cambiar el color de todos los textos a negro.

Texto rojo = Comentarios

Texto negro = Contribución de Simón y Mauricio

Texto en verde = Completar para el 1er entregable

Texto en azul = Completar para el 2° entregable

Texto en violeta = Completar para el tercer entregable

RESUMEN

Actualmente la industria ganadera proporciona un tercio de las proteínas consumidas en la dieta humana. Desde hace unos años se presenta un concepto llamado Ganadería de Precisión (GdP), la cual permita unir la tecnología con la ganadería permitiendo así la mejora de esta.

Con base a lo anterior, se diseñará un algoritmo basado en tablas de hash y árboles con el fin de comprimir y descomprimir imágenes para alcanzar la mayor exactitud y reducción del consumo de energía en el contexto de la ganadería. El algoritmo permitirá clasificar la salud del animal. Las imágenes se comprimirán con la máxima tasa de compresión, sin afectar la exactitud en más de 5%

El software y la ganadería ya han estado en contacto, por medio de otros estudios que han trabajado con animales de granja, tales como: entre ellos se encuentra la integración de servicios en la nube para estudios del comportamiento de animales de granja basados en teléfonos inteligentes como sensores de actividad; otro es la localización visual e identificación del ganado Holstein Friesian mediante aprendizaje profundo; por ultimo una plataforma de bienestar animal para los sistemas de producción de ganadería extensiva.

¿Cuál es el algoritmo propuesto? ¿Qué resultados obtuviste? ¿Cuáles son las conclusiones de este trabajo? El resumen debe tener como máximo 200 palabras. (En este semestre, deberías resumir aquí los tiempos de ejecución, el consumo de memoria, la tasa de compresión y la exactitud).

Palabras clave

Algoritmos de compresión, aprendizaje de máquina, aprendizaje profundo, ganadería de precisión, salud animal.

1. INTRODUCCIÓN

En 1536 Sebastián de Belalcázar fue uno de los primeros pioneros en traer desde “La Española” actualmente Haití y República Dominicana en traer en ganado bovino a Colombia, esto debido a que la carne en su época venia de especies silvestres que eran originarias del país, las cuales no permitían una adecuada alimentación. Posteriormente se realiza una expansión por los departamentos de la Región Caribe.

La ganadería se veía como una industria prometedora en sectores donde no había minería, sin embargo, no se veía promisoría para las áreas donde existía la minería. En la actualidad colombiana la ganadería es considerada una de las actividades económicas más importantes para el futuro colombiano, ya que está en constante expansión y se espera que a futuro haya exportaciones y supere las calidades del mercado internacional.

Así mismo, la ganadería es fundamental por sus bienes y servicios que presta a la sociedad, como la diversidad de productos de carne, leche, queso, cuero, otras fibras y el uso de los animales para el arado y transporte de carga. Al mismo tiempo, como componente esencial de la agricultura mundial.

Para poder hacer el seguimiento de la salud de los bovinos, se requiere implementar un sistema de vigilancia para el cuidado de ellos. Para esto es requerido el reconocimiento de todos los especímenes, y la mejor forma de hacerlo es por medio de fotografías. Sin embargo, hay que tener en cuenta que van a haber muchas cabezas de ganado, por esta razón se necesitan muchas fotografías que implican gran cantidad de espacio en memoria. Por tanto, teniendo presente lo anterior se requiere la compresión de estas imágenes. Así que por estas razones se procederá a realizar un software que permita realizar la compresión y el posterior análisis de las imágenes.

1.1. Problema

Durante el transcurso de los tiempos, la ganadería y la agricultura se han encargado de abastecer las necesidades de los seres humanos centrándose así en mejorar los precios y la competitividad en estos ámbitos. Sin embargo, en los últimos años se ha presentado un pensamiento más animalista, procurando así que, a pesar de la producción de los alimentos procedentes de los animales, se tenga presente también el respeto al animal como ser que siente. Además,

se han presentado estudios que indican que la salud de los consumidores está directamente relacionada con la salud de los animales y un mejor producto para la venta.

1.2 Solución

En este trabajo, utilizamos una red neuronal convolucional para clasificar la salud animal, en el ganado vacuno, en el contexto de la ganadería de precisión (GdP). Un problema común en la GdP es que la infraestructura de la red es muy limitada, por lo que se requiere la compresión de los datos.

Expliquen, brevemente, su solución al problema (En este semestre, la solución es una implementación de algoritmos de compresión. ¿Qué algoritmos han elegido? ¿Por qué?)

1.3 Estructura del artículo

En lo que sigue, en la Sección 2, presentamos trabajos relacionales con el problema. Más adelante, en la Sección 3, presentamos los conjuntos de datos y los métodos utilizados en esta investigación. En la Sección 4, presentamos el diseño del algoritmo. Después, en la Sección 5, presentamos los resultados. Finalmente, en la Sección 6, discutimos los resultados y proponemos algunas direcciones de trabajo futuras.

2. TRABAJOS RELACIONADOS

En lo que sigue, explicamos cuatro trabajos relacionados. en el dominio de la clasificación de la salud animal y la compresión de datos. en el contexto del PLF.

2.1. UNA REVISIÓN SISTEMÁTICA DE LA BIBLIOGRAFÍA SOBRE EL USO DEL MACHINE LEARNING EN LA GANADERÍA DE PRECISIÓN.

El artículo que se presenta hace una revisión sistemática de la bibliográfica sobre los trabajos recientes realizados utilizando Machine Learning para el sector de la ganadería más enfocado a la ganadería de precisión. Este artículo se centra más que todo en dos áreas: El pastoreo y la salud del animal. En este artículo presenta las oportunidades para en Machine Learning en el sector ganadero, muestra qué avances ha habido en el análisis de datos, detalla el incremento de apertura de fuentes de datos.

Los algoritmos que presentan en este artículo son: Simple Logistic (SL); Logistic model trees (LMT), MLP, Naive Bayes (NB), DT, SVM, Naive Bayes tree (NBTree), Logistic Model Trees (LMT) and Sequential Minimal Optimization (SMO).

El resultado de este trabajo arrojó que el Machine Learning apenas está en etapa de desarrollo y tiene diferentes desafíos tales como desarrollar modelos de diagnóstico como prevención y control de enfermedades en los bovinos en el PLF; dar autonomía a la PLF mediante ciclos autónomos de tareas de análisis de datos y meta-aprendizaje, y reunir las

variables del suelo y del pasto ya que son importantes para la salud animal y de pastoreo.[1]

2.2. UNA PLATAFORMA DE BIENESTAR PARA SISTEMAS EXTENSIVOS DE PRODUCCIÓN GANADERA.

El estudio actual presenta el progreso continuo del desarrollo de un sistema automatizado con un solo tipo de sensor inalámbrico capaz de registrar indicadores del bienestar del animal (es decir, información de movimiento, velocidad y geolocalización del animal) con bajo costo de implementación, basado en Deep Neural Algoritmos de reconocimiento de patrones de red. La solución también proporciona a los usuarios finales (agricultores) visualizaciones de información útiles y efectivas, para que tomen las acciones adecuadas.

De acuerdo con la información anterior, los algoritmos que presentan en este artículo son algoritmos de reconocimiento de patrones de redes neurales profundas.

El presente estudio presenta una solución para el seguimiento y monitoreo de la actividad y el comportamiento de los animales en las fincas ganaderas, obteniendo indicadores que sustentan el bienestar animal. La solución, I. un solo tipo de sensor inalámbrico (dispositivo de collar) para registrar la actividad de los animales como: el movimiento, velocidad, geolocalización, con un bajo costo de implementación, II. dispositivos de computación con capacidades computacionales, capaces de realizar procesamiento de datos desconectados y en tiempo real para el reconocimiento de patrones a través de algoritmos de redes neuronales profundas, III. Computación en la nube para datos y almacenamiento de modelos de aprendizaje profundo y IV visualizaciones utilizables y efectivas en dispositivos móviles que brindan a los agricultores información valiosa. El sistema ha sido desarrollado para el manejo de ovejas de granjas extensivas en la prefectura de Epiro y será validado en dos casos de uso: primero, monitoreo de los principales indicadores de bienestar 6 de las ovejas en un sistema productivo semi extensivo; y segundo, evaluación de las medidas de bienestar del ganado. en un sistema de crianza extensiva.[2]

2.3. INTEGRACIÓN DE SERVICIOS EN LA NUBE PARA EL COMPORTAMIENTO DE ANIMALES DE GRANJA BASADOS EN TELÉFONOS INTELIGENTES COMO SENSORES DE ACTIVIDAD.

Los teléfonos inteligentes, particularmente el iPhone, pueden ser instrumentos relevantes para los investigadores en comportamiento animal porque están fácilmente disponibles en el planeta, contienen muchos sensores y no requieren desarrollo de hardware. Están equipados con Unidades de Medida Inercial (IMU) de alto rendimiento y sistemas de

posicionamiento absoluto que analizan los movimientos de los usuarios, pero pueden ser fácilmente desviados para analizar igualmente los comportamientos de animales domésticos como el ganado. El estudio del comportamiento animal utilizando teléfonos inteligentes requiere el almacenamiento de muchas variables de alta frecuencia de muchos individuos y su procesamiento a través de varias combinaciones de variables relevantes para el modelado y la toma de decisiones. Transferir, almacenar, tratar y compartir tal cantidad de datos es un gran desafío. En este artículo, se propone una arquitectura de nube lambda acoplada de manera innovadora a una plataforma de intercambio científico utilizada para archivar y procesar datos de alta frecuencia para integrar los desarrollos futuros de Internet de las cosas aplicados al monitoreo de animales domésticos. Se ejemplifica una aplicación al estudio del comportamiento del ganado en pastos basada en los datos registrados con la IMU de iPhone 4s. También se logra una comparación de rendimiento entre el iPhone 4s y el iPhone 5s. El paquete también viene con una interfaz web para codificar el comportamiento real observado en los videos y sincronizar las observaciones con las señales del sensor. Finalmente, el uso de Edge Computing en el iPhone redujo en un 43,5% en promedio el tamaño de los datos sin procesar al eliminar las redundancias. La limitación del número de dígitos en una variable individual puede reducir la redundancia de datos hasta en un 98,5%.

Para el caso de este artículo, se presenta una aplicación llamada Xamarin, la cual permite medir la compresibilidad de los archivos. Sin embargo, en este artículo no se menciona algún algoritmo de compresibilidad de datos, simplemente se menciona que es debido considerar optimizarlos para mejorar el consumo de batería de los dispositivos con los que se trabajó.

Para el artículo, se muestra en conclusión que la nueva arquitectura que ellos presentan es útil para utilizarla de forma portátil, permite la recopilación de datos a alta frecuencia y se adapta fácilmente a muchos casos. Es utilizando en equipos celulares de iPhone, tales como el 5SE, 6S, 7S y 8S, los cuales están calibrados con un nuevo IMU (Unidad de Medición Inercial). Estos equipos son un medio económico para medir el comportamiento del ganado bovino. Sin embargo, se debe de tener presente que, si se utilizan varios dispositivos en simultáneo, va a haber una pérdida de datos. También, se debe considerar buscar otros algoritmos de compresión de datos para optimizar el consumo de energía de la batería. [3]

2.4. LOCALIZACIÓN VISUAL E IDENTIFICACIÓN INDIVIDUAL DEL GANADO HOLSTEIN FRIESIAN MEDIANTE APRENDIZAJE PROFUNDO (DEEP LEARNING).

Este artículo nos presenta una demostración de que la revisión por computadora de los oleoductos se puede utilizar

con arquitectura neuronal profunda sobre la detección automatizada del ganado Holstein Friesian así como la identificación individual de configuraciones agrícolas relevantes.

Demostraron que las redes estándar pueden realizar la identificación completa de los individuos en imágenes fijas de arriba hacia abajo adquiridas por medio de una cámara fija. Luego, presentamos una canalización de procesamiento de video compuesta por componentes estándar para procesar de manera eficiente el dinamismo del ganado filmado por un dron. Informamos sobre estas configuraciones, así como el contexto, la capacitación y la evaluación de todos sus componentes.

Demostraron que la detección y localización del ganado Friesian se puede realizar de forma robusta con una precisión del 99,3% en estos datos. Se evaluó la identificación individual aprovechando la singularidad del pelaje por medio de equipos RGB tomados después del ordeño con 89 individuos y una precisión de 86,1%. También se evaluó la identificación a través de canalización de procesamiento de video en 46.430 cuadros provenientes de 34 videos, cada uno de aproximadamente 20 segundos de duración tomadas por el dron durante el pastoreo, con 23 individuos y una precisión de 98.1%.

El algoritmo implementado en el presente artículo es un algoritmo de comprensión de imágenes y canalización de componentes. El diseño del algoritmo es una línea que utiliza entradas de imágenes fijas y comprende un R-CNN VGG-M 1024 (Receptor de imagen y video) de extremo a extremo para la identificación individual del ganado. También posee una antena de seguimiento y una unidad de trayectoria (KCF) única a un componente de identificación individual que utiliza redes de información complementaria

El artículo concluye que es posible realizar una identificación del ganado sin necesidad de utilizar métodos de etiquetado existentes en la actualidad; el cual es un proceso intrusivo y dañino para el animal. Esto por medio de la utilización de componentes estándar de aprendizaje profundo. Para la identificación, se demostró que las arquitecturas basadas en convolución son muy adecuadas para aprender y distinguir las propiedades del patrón y la estructura dorsal únicos exhibidos por las especies individualmente. El video capturado fue analizado por el LRCN fuera de línea. El cual demostró que, para el artículo en cuestión, fue demostrado que resultar suficiente en los escenarios presentados. [4]

3. MATERIALES Y MÉTODOS

En esta sección, explicamos cómo se recogieron y procesaron los datos y, después, diferentes alternativas de algoritmos de compresión de imágenes para mejorar la clasificación de la salud animal.

3.1 Recopilación y procesamiento de datos

Recogimos datos de *Google Images* y *Bing Images* divididos en dos grupos: ganado sano y ganado enfermo. Para el ganado sano, la cadena de búsqueda era "cow". Para el ganado enfermo, la cadena de búsqueda era "cow + sick".

En el siguiente paso, ambos grupos de imágenes fueron transformadas a escala de grises usando Python OpenCV y fueron transformadas en archivos de valores separados por comas (en inglés, CSV). Los conjuntos de datos estaban equilibrados.

El conjunto de datos se dividió en un 70% para entrenamiento y un 30% para pruebas. Los conjuntos de datos están disponibles en <https://github.com/mauriciotoro/ST0245-Eafit/tree/master/proyecto/datasets>.

Por último, utilizando el conjunto de datos de entrenamiento, entrenamos una red neuronal convolucional para la clasificación binaria de imágenes utilizando *Teachable Machine* de Google disponible en <https://teachablemachine.withgoogle.com/train/image>.

3.2 Alternativas de compresión de imágenes sin pérdida

3.2.1 Algoritmo Borrows Wheeler:

Es un algoritmo sin pérdidas, es utilizado para la compresión de datos como en bzip2. Cuando se transforma una cadena de caracteres mediante la BTW, ningún carácter cambia de valor. Si la cadena contiene muchas sub cadenas, entonces la cadena transformada contendrá múltiples opciones en las que el mismo carácter este repetido varias veces.

Es muy útil para la compresión de archivos, ya que tiende a ser fácil comprimir una cadena que tiene una secuencia de caracteres repetidos con técnicas como: move-to-front-transform y run-length encoding.

Ejemplo:

Entrada	SIX.MIXED.PIXIES.SIFT.SIXTY.PIXIE.DUST.BOXES
Salida	TEXYDST.E.IXIXIXSSMPPS.B..E.S.EUSFXDIIIOIIIT

La salida es más fácil de comprimir ya que tiene muchos caracteres repetidos. De hecho, en la cadena transformada.

aparece un total de seis secuencias de caracteres idénticos:

XX, SS, PP, ..., II, y III, que juntos representan 13 de los 44 caracteres. [5]

3.2.2 Algoritmo PNG:

PNG: Es un algoritmo de compresión sin pérdidas para bitmaps. Este formato fue desarrollado para solventar las deficiencias del formato gif y permita almacenar imágenes

con mayor profundidad de contraste y otros datos importantes.


El método de compresión utilizado por el PNG es conocido como deflación (Algoritmo sin pérdidas). También tiene métodos de filtrado de información en píxeles, el más utilizado es prediciendo el valor aproximado de los píxeles lo cual mejora la comprensión para cada línea de la imagen a comprimir. En otras palabras, este método de filtrado predice el color de cada píxel basándose en los colores de los píxeles previos a comprimir, restándolos con los actuales, Lo cual reduce el tamaño del archivo de imagen. [6]

Profundidad de bits por canal	1	2	4	8	16
Imagen indexada (1 canal)	1	2	4	8	
Escala de grises (1 canal)	1	2	4	8	16
Escala de grises con alfa (2 canales)				16	32
Color verdadero (RGB) (3 canales)				24	48
Color verdadero con alfa (RGBA) (4 canales)				32	64

3.3.1 Codificación de Huffman

Es un algoritmo usado para la compresión de datos. Se refiere al uso de una tabla de códigos de longitud variable para codificar determinado símbolo, donde la tabla ha sido rellena de tal forma que se basa en la probabilidad estimada de aparición de cada de cada posible valor de dicho símbolo.

La codificación de Huffman usa un método específico para elegir la representación de cada símbolo, que representa los caracteres más comunes usando las cadenas de bits más cortas, y viceversa.

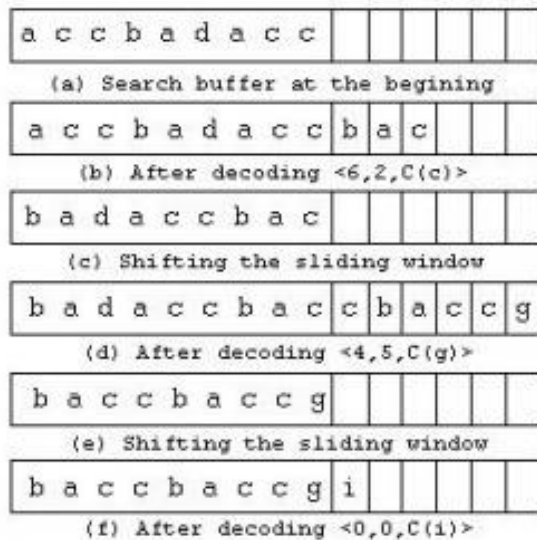


Un ejemplo de un árbol dibujado es el siguiente donde los nodos hijos finales son a los que les corresponde un símbolo y una frecuencia, y los nodos padres de estos últimos se conectan como pequeños árboles a otros nodos. Los nodos con puros números indican la suma de las frecuencias de los nodos hijos correspondientes. [7]

3.3.2 LZ77

Los algoritmos LZ77 logran la compresión reemplazando las apariciones repetidas de datos con referencias a una sola copia de esos datos existente anteriormente en el flujo de datos sin comprimir.

Para detectar coincidencias, el codificador debe realizar un seguimiento de cierta cantidad de los datos más recientes, como los últimos 2 kB, 4 kB o 32 kB. La estructura en la que se guardan estos datos se denomina ventana deslizante, por lo que LZ77 a veces se denomina compresión de ventana deslizante. El codificador necesita mantener estos datos para buscar coincidencias, y el decodificador necesita mantener estos datos para interpretar las coincidencias a las que se refiere el codificador. Cuanto más grande sea la ventana deslizante, más atrás podrá buscar el codificador para crear referencias.[8]



3.3 Alternativas de compresión de imágenes con pérdida


3.3.1 Codificación por transformación

Es un tipo de compresión para datos naturales como: Audio, video e imagen, la transformación conlleva pérdida de información, resultando una copia de menor calidad a la que entra originalmente.

Un ejemplo de esto es la televisión, que utiliza sistemas de compresión por transformación como:

NTSC: Este es uno de los sistemas de codificación por transformación con mayor éxito – se enfocó en el formato de televisión a color. Este conocimiento permitió desarrollar un sistema que descartara mayor parte de la señal entrante, el resultado fue una señal con menos contenido que encaja en los 6MHz de señal a blanco y negro con una diferencia modulada.

PAL y SECAM: Estos sistemas utilizan métodos muy parecidos para transmitir color.[9]

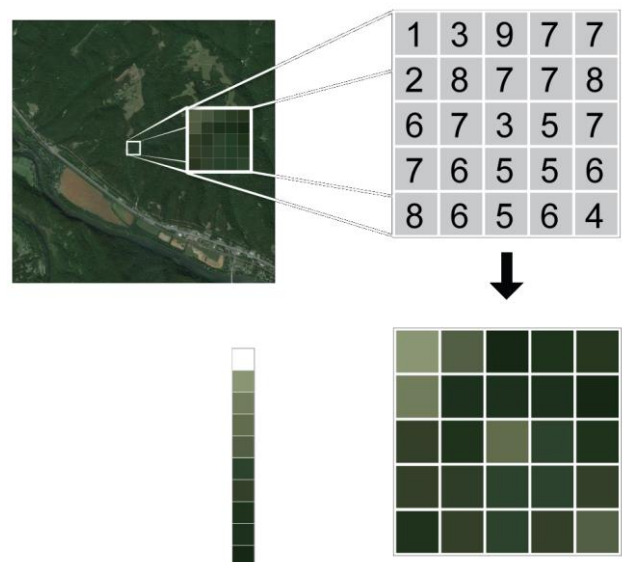


3.3.2 MrSid

Es un algoritmo de compresión de imágenes con pérdida y un estándar abierto de compresión de imágenes raster (Estructuras de píxeles), permite mostrar archivos digitales de gran tamaño con un tiempo de carga mínimo gracias a tecnologías ondículas (Transforma las señales en gráficas y algoritmos matemáticos).

La característica predominante del formato es el teselado (Patrón de figureas) que logra una alta compresión de imágenes digitales con la pérdida mínima de detalle. El teselado da la capacidad de descomprimirse solamente aquella porción de imagen solicitada por el usuario, extrayendo y entregando únicamente los bitplanes y datos raster necesarios para construir la vista requerida.

Datos raster: También conocido como mapa de bits o plano de bits, son datos representados por medio de píxeles o puntos de color, que se pueden visualizar por medio de monitores u otros dispositivos (Tiene cierta relación con el PNG). [10]



3.3.3 Compresión fractal

La compresión fractal es un método de compresión con pérdida para imágenes digitales, basado en fractales. El método es el más apropiado para texturas e imágenes naturales, basándose en el hecho de que partes de una

imagen, a menudo, se parecen a otras partes de la misma imagen. Los algoritmos fractales convierten estas partes en datos matemáticos llamados «códigos fractales» los cuales se usan para recrear la imagen codificada.

Con la compresión fractal, la codificación es extremadamente cara a nivel computacional debido a la búsqueda de similitudes propias. Sin embargo, la decodificación es bastante rápida. Mientras que esta asimetría lo hace poco práctico para aplicaciones en tiempo real, cuando el vídeo es guardado para distribución desde un disco, la compresión fractal llega a ser más competitiva. [11]




Fig. 3.2.1 A partitioned iterated function system.

3.3.4 Joint Photographic Experts Group (JPEG)

JPEG utiliza una forma de compresión con pérdida basada en la transformada de coseno discreta (DCT). Esta operación matemática convierte cada cuadro / campo de la fuente de video del dominio espacial (2D) al dominio de frecuencia (también conocido como dominio de transformación).

Un modelo perceptivo basado libremente en el sistema psicovisual humano descarta información de alta frecuencia, es decir, transiciones bruscas en intensidad y tono de color. En el dominio de la transformación, el proceso de reducción de información se denomina cuantificación. En términos más simples, la cuantificación es un método para reducir de manera óptima una escala de números grandes (con diferentes ocurrencias de cada número) en una más pequeña.

El método de compresión suele tener pérdidas, lo que significa que parte de la información de la imagen original se pierde y no se puede restaurar, lo que posiblemente afecte a la calidad de la imagen.

A continuación, cada bloque de 8×8 de cada componente (Y, Cb, Cr) se convierte en una representación de dominio de frecuencia, utilizando una transformada de coseno discreta (DCT) de tipo II bidimensional normalizada: [12]

52	55	61	66	70	61	64	73
63	59	55	90	109	85	69	72
62	59	68	113	144	104	66	73
63	58	71	122	154	106	70	69
67	61	68	104	126	88	68	70
79	65	60	70	77	68	58	75
85	71	64	59	55	61	65	83
87	79	69	68	65	76	78	94

4. DISEÑO E IMPLEMENTACIÓN DE LOS ALGORITMOS

En lo que sigue, explicamos las estructuras de datos y los algoritmos utilizados en este trabajo. Las implementaciones de las estructuras de datos y los algoritmos están disponibles en Github¹

4.1 Estructuras de datos

Explique la estructura de datos utilizada para hacer la compresión de las imágenes y haga una figura que la explique. No utilice figuras de Internet. (En este semestre, ejemplo de las estructuras de datos son los árboles y las tablas hash)




Figura 1: Árbol de Huffman generado a partir de las frecuencias exactas del texto "this". (Por favor, no dude en cambiar esta figura si utilizan una estructura de datos diferente).

4.2 Algoritmos

En este trabajo, proponemos un algoritmo de compresión que es una combinación de un algoritmo de compresión de imágenes con pérdidas y un algoritmo de compresión de imágenes sin pérdidas. También explicamos cómo funciona la descompresión para el algoritmo propuesto.

Expliquen el diseño de los algoritmos para resolver el problema y hagan una figura. No uses figuras de Internet, haz

¹[http://www.github.com/ ???????? /proyecto/](http://www.github.com/?????????/proyecto/)

las tuyas propias. (En este semestre, un algoritmo debe ser un algoritmo de compresión de imágenes con pérdidas, como el escalado de imágenes, el tallado de costuras o la compresión con ondeletas, y el segundo algoritmo debe ser un algoritmo de compresión de imágenes sin pérdidas, como la codificación Huffman, LZS o LZ77).

4.2.1 Algoritmo de compresión de imágenes con pérdida

Explique, brevemente, cómo se aplicó un algoritmo de compresión de imágenes con pérdidas, como, por ejemplo, el tallado de costuras o el escalado de imágenes. Explique también la descompresión.




Figura 2: Escalado de la imagen mediante interpolación bilineal. (Por favor, siéntase libre de cambiar esta figura si utiliza una estructura de datos diferente).

4.2.2 Algoritmo de compresión de imágenes sin pérdida

Explique brevemente cómo aplicó un algoritmo de compresión de imágenes sin pérdidas como la codificación Huffman, LZS o LZ77. Explique también la descompresión.

4.3 Análisis de la complejidad de los algoritmos

Explique, con sus propias palabras, el análisis del peor caso usando la notación O. ¿Cómo calculó tales complejidades. Por favor, explique brevemente.

Algoritmo	La complejidad del tiempo
Compresión	$O(N^2 \cdot M^2)$
Descompresión	$O(N^3 \cdot M \cdot 2^N)$

Tabla 2: Complejidad temporal de los algoritmos de compresión y descompresión de imágenes. (Por favor, explique qué significan N y M en este problema).

Algoritmo	Complejidad de la memoria
Compresión	$O(N \cdot M \cdot 2N)$
Descompresión	$O(2M \cdot 2N)$

Tabla 3: Complejidad de memoria de los algoritmos de compresión y descompresión de imágenes. (Por favor, explique qué significan N y M en este problema).

4.4 Criterios de diseño del algoritmo

Explique por qué el algoritmo fue diseñado de esa manera. Use un criterio objetivo. Los criterios objetivos se basan en la eficiencia, que se mide en términos de tiempo y consumo de memoria. Ejemplos de criterios no objetivos son: "Estaba enfermo", "fue la primera estructura de datos que encontré en Internet", "lo hice el último día antes del plazo", etc. Recuerde: Este es el 40% de la calificación del proyecto.

5. RESULTADOS

5.1 Evaluación del modelo

En esta sección, presentamos algunas métricas para evaluar el modelo. La exactitud es la relación entre el número de predicciones correctas y el número total de muestras de entrada. La precisión es la proporción de estudiantes exitosos identificados correctamente por el modelo a estudiantes exitosos identificados por el modelo. Por último, sensibilidad es la proporción de estudiantes exitosos identificados correctamente por el modelo a estudiantes exitosos en el conjunto de datos.

5.1.1 Evaluación del conjunto de datos de entrenamiento

A continuación, presentamos las métricas de evaluación del conjunto de datos de entrenamiento en la Tabla 3.

	Conjunto de datos de entrenamiento
Precisión	0.02
Precisión	0.03
Recordar	0.01

Tabla 3. Evaluación del modelo de clasificación de imágenes con el conjunto de datos de entrenamiento.

5.1.2 Evaluación del conjuntos de datos de prueba

A continuación presentamos las métricas de evaluación del conjunto de datos de prueba, en la Tabla 4, sin compresión y, en la Tabla 5, con compresión.

	Conjunto de datos de prueba
Exactitud	0.01
Precisión	0.012
Sensibilidad	0.013

Tabla 4. Evaluación del modelo de clasificación de imágenes, con el conjunto de datos de prueba, sin compresión.

	<i>Conjunto de datos de prueba</i>
<i>Exactitud</i>	0.001
<i>Precisión</i>	0.0012
<i>Sensibilidad</i>	0.0013

Tabla 5. Evaluación del modelo de clasificación de imágenes, con el conjunto de datos de prueba, con compresión.

5.2 Tiempos de ejecución

En lo que sigue explicamos la relación entre el tiempo promedio de ejecución y el tamaño promedio de las imágenes del conjunto de datos completo, en la Tabla 6.

Calcular el tiempo de ejecución de cada imagen en Github. Informar del tiempo medio de ejecución vs. el tamaño medio del archivo.

	<i>Tiempo promedio de ejecución (s)</i>	<i>Tamaño promedio del archivo (MB)</i>
<i>Compresión</i>	100.2 s	12.4 MB
<i>Descompresión</i>	800.1 s	12.4 MB

Tabla 6: Tiempo de ejecución de los algoritmos (Por favor, escriba el nombre de los algoritmos, por ejemplo, tallado de costuras y LZ77) para diferentes imágenes en el conjunto de datos.

5.3 Consumo de memoria

Presentamos el consumo de memoria de los algoritmos de compresión y descompresión en la Tabla 7.

	<i>Consumo promedio de memoria (MB)</i>	<i>Tamaño promedio del archivo (MB)</i>
<i>Compresión</i>	634 MB	3.12 MB
<i>Descompresión</i>	9 MB	878.12 MB

Tabla 7: Consumo promedio de memoria de todas las imágenes del conjunto de datos, tanto para la compresión como para la descompresión.

Para medir el consumo de memoria, deberían usar un generador de perfiles. Uno muy bueno para Java es VisualVM, desarrollado por Oracle, <http://docs.oracle.com/javase/7/docs/technotes/guides/visualvm/profiler.html>. Para Python, usa el *C profiler*.

5.3 Tasa de compresión

Presentamos los resultados de la tasa de compresión del algoritmo en la Tabla 8.

	<i>Ganado sano</i>	<i>Ganado enfermo</i>
<i>Tasa de compresión promedio</i>	1:23	1:34

Tabla 8: Promedio redondeado de la tasa de compresión de todas las imágenes de ganado sano y ganado enfermo.

6. DISCUSIÓN DE LOS RESULTADOS

Explique los resultados obtenidos. ¿Son la exactitud, la precisión y la sensibilidad apropiadas para este problema? ¿El modelo está sobreajustado? ¿Es apropiado el consumo de memoria y el consumo de tiempo? ¿Es la relación de compresión apropiada? ¿Cambia la compresión significativamente la exactitud con el conjunto de datos de la prueba? (En este semestre, según los resultados, ¿puede la compresión mejorar la clasificación de la salud animal en el contexto del PLF?)

6.1 Trabajos futuros

Responda ¿qué le gustaría mejorar en el futuro? ¿Cómo le gustaría mejorar su algoritmo y su implementación? ¿Qué tal usar la transformación de coseno discreto o la compresión con ondeletas a futuro?

RECONOCIMIENTOS

Identifique el tipo de reconocimiento que quiere escribir: para una persona o para una institución. Considere las siguientes pautas: 1. El nombre del profesor no se menciona porque es un autor. 2. No debe mencionar sitios web de autores de artículos que no ha contactado. 3. Debe mencionar estudiantes, profesores de otros cursos que le hayan ayudado.

Como ejemplo: Esta investigación fue apoyada/parcialmente apoyada por [Nombre de la Fundación, Donante, Beca].

Agradecemos la asistencia con [técnica particular, metodología] a [Nombre Apellido, cargo, nombre de la institución] por los comentarios que mejoraron enormemente el manuscrito o la codificación del algoritmo.

REFERENCIAS

- [1] Rodrigo García, Jose Aguilar, Mauricio Toro, Ángel Pin y Paul Rodríguez. 2020. A systematic literature review on the use of machine learning in precision livestock farming. *ELSEVIER* 179, 105826. (Dec. 2020) 1 – 12. DOI: <https://doi.org/10.1016/j.compag.2020.105826>
- [2] Vasileios Doulgerakis, Dimitrios Kalyvas, Enkeleda Bocaj, Christos Giannousis, Michalis Fcidakis, George P. Laliotis, Charalampos Patrikakis y Losif Bizelis. 2019. An animal welfare platform for extensive livestock production systems. *European Conference on Ambient Intelligence*. (Nov. 2019) 1 – 7. CEUR: <http://ceur-ws.org/Vol-2492/paper1.pdf>
- [3] Debauche, O., Mahmoudi, S., Andriamandroso, A.L.H. et al. Cloud services integration for farm animals' behavior studies based on smartphones as activity sensors. *J Ambient Intell Human Comput* 10, 4651–4662 (2019). <https://doi.org/10.1007/s12652-018-0845-9>
- [4] Andrew, W., Greatwood, C., & Burghardt, T. (2018). Visual Localisation and Individual Identification of Holstein Friesian Cattle via Deep Learning. In 2017 IEEE International Conference of Computer Vision Workshop (ICCVW 2017) (pp. 2850-2859). Institute of Electrical and Electronics Engineers (IEEE). <https://doi.org/10.1109/ICCVW.2017.336>
- [5] Wikipedia. 2021. Compresión de Borrowers-Wheeler. Retrieval from https://es.wikipedia.org/w/index.php?title=Compresi%C3%B3n_de_Burrows-Wheeler&oldid=133166733
- [6] Wikipedia. 2021. Portable Network Graphics. Retrieval from https://es.wikipedia.org/w/index.php?title=Portable_Network_Graphics&oldid=136457907
- [7] Wikipedia. 2021. Codificación Huffman, Retrieval from https://es.wikipedia.org/wiki/Codificaci%C3%B3n_Huffman
- [8] Wikipedia. 2021. LZ77, Retrieval from https://en.wikipedia.org/wiki/LZ77_and_LZ78
- [9] Wikipedia. 2020. Codificación por transformación. Retrieval from https://es.wikipedia.org/w/index.php?title=Codificaci%C3%B3n_por_transformaci%C3%B3n&oldid=127103029
- [10] Wikipedia. 2019. MrSid. Retrieval from <https://es.wikipedia.org/w/index.php?title=MrSID&oldid=17890397>
- [11] Wikipedia. 2021. Compresión fractal. Retrieval from https://es.wikipedia.org/wiki/Compresi%C3%B3n_fractal
- [12] Wikipedia. 2021. JPEG. Retrieval from <https://en.wikipedia.org/wiki/JPEG>